

Analyse Prédictive & Segmentation Clientèle

Comportement Client — Churn — Dépenses

01 Contexte — Le Problème Métier

Contexte

Une plateforme e-commerce spécialisée dans la vente de cadeaux cherche à mieux comprendre sa clientèle pour prendre des décisions marketing basées sur les données.

Le défi :

- Base de données réelle — intentionnellement imparfaite
- 4 372 clients décrits par 52 features hétérogènes
- Valeurs manquantes, aberrantes, formats inconsistants
- Déséquilibre des classes : 67% fidèles / 33% churners

3 Questions Stratégiques



**Qui sont
mes clients ?**

K-Means Clustering



**Qui risque
de partir ?**

Classification Churn




**Combien vont-ils
dépenser ?**


Régression

01 Architecture du Projet & Description des Données

Chaîne de traitement complète



Le dataset




02 Exploration — Qualité des Données

Chaque anomalie a été identifiée et traitée avant toute modélisation.

Type de problème	Feature	Fréquence	Traitement
 Valeurs manquantes	Age	30%	Imputation par médiane
 Valeurs aberrantes	SupportTickets	5-8%	Sentinelles 999, -1 → NaN
 Valeurs aberrantes	SatisfactionScore	5-8%	Valeurs -1, 0, 99 → NaN
 Formats inconsistants	RegistrationDate	100%	Parsing & standardisation
 Feature inutile	NewsletterSubscribed	100%	Variance nulle → Supprimée
 Données brutes	LastLoginIP	100%	Extraction de sous-features

02 Exploration — Distribution & Corrélations

Distribution de la variable cible — Churn



Déséquilibre 67% / 33% — Traité par SMOTE (génération synthétique de cas minoritaires)

Corrélations clés détectées

MonetaryTotal ↔ MonetaryMin / Max

Très forte

TotalQuantity ↔ Frequency

Forte

Recency ↔ Churn

Modérée


SatisfactionScore ↔ Churn

Faible

→ 19 features multicollinéaires supprimées ($|corr| > 0.8$)

03 Préparation des Données

Pipeline de prétraitement (8 étapes)



Features créées par ingénierie

MonetaryPerDay

$MonetaryTotal / (Recency + 1)$

Dépense par jour d'inactivité

AvgBasketValue

$MonetaryTotal / Frequency$

Valeur moyenne d'un panier

TenureRatio

$Recency / (CustomerTenure + 1)$

Ratio inactivité / ancienneté

52 → 88

features après encodage

0

valeurs manquantes

80% / 20%

split stratifié sur Churn

04 Clustering K-Means — Segmentation Clientèle

ACP (pré-clustering) : 68 features → 42 composantes principales avec 95% de variance préservée

K = 4 retenu — méthode du coude + score silhouette maximal

0 Champions

R↑ F↑ M↑

Acheteurs très récents, fréquents, forte valeur monétaire. Clients les plus précieux.

1 Fidèles

R→ F→ M→

Achats réguliers, bonne valeur, ancienneté élevée. Base solide à conserver.

2 Potentiels

R→ F↓ M↓

Clients prometteurs avec fréquence modérée. Cibles prioritaires de fidélisation.


3 Dormants

R↓ F↓ M↓

Inactifs depuis longtemps, faible engagement. Cibler avec campagnes de réactivation.

05 Classification — Prédiction du Churn

Comparaison AUC & F1-Score



✓ Meilleur modèle : Random Forest — AUC = 1.00 | F1 = 1.00 | 0 faux négatifs

Métriques clés & Insights

Précision 100% Tous les churners détectés sont vrais

Rappel 100% Aucun churning manqué (priorité #1)

SMOTE Bal. Rééquilibrage synthétique 67/33

GridSearch CV×3 $n_estimators \in \{50, 100\}$, $max_depth \in \{10, 20\}$

Top 5 features prédictives

24%

Recency

17%

TenureRatio

12%

FavoriteSeason

10%


FirstPurchase

9%

CustomerType

05 Régression — Prédiction du Montant Dépensé

Comparaison RMSE (£) — plus bas = meilleur



✓ **Random Forest** — RMSE : 7 835£ | R^2 : 52.3% (+13 pts vs Régression Linéaire)

Score R^2 par modèle

Linear Regression

R^2 39.3%

Ridge ($\alpha=1.0$)

R^2 39.3%

Ridge ($\alpha=10$)

R^2 39.1%

Random Forest

R^2 52.3%

RMSE = erreur moyenne en £ | R^2 = % de variance expliquée par le modèle

06 Déploiement — Application Flask

Pipeline de prédiction en production



Routes de l'API

GET	/	Interface HTML utilisateur
POST	/predict	Prédiction churn + segment client
GET	/health	Vérification API opérationnelle

Exemple de réponse JSON

```
{
  "churn_prediction": 1,
  "churn_probability": 92.0,
  "churn_label": "Risque de départ",
  "cluster": 2,
  "segment": "Potentiels"
}
```

06 Interface Utilisateur

Ce que fait l'interface

Formulaire de saisie des données client (6 champs)

Prédiction instantanée via POST /predict

Affichage du risque de churn avec probabilité %

Identification du segment RFM (cluster)

Serveur Flask local — <http://127.0.0.1:5000>

Capture d'écran — Interface Web

Analyse Comportementale Clientèle

Prédiction du Churn et Segmentation Client

Recency (jours depuis dernier achat)
30

Frequency (nombre de commandes)
5

MonetaryTotal (total dépensé £)
500

Age
35

CustomerTenureDays (ancienneté en jours)
365

SatisfactionScore (1 à 5)
4

Analyser ce client

Statut : Risque de départ
Probabilité de churn : 92%
Segment : Potentiels

Conclusion & Recommendations



AUC 1.00

Random Forest — Churn parfait



R² 52.3%

Random Forest — Dépenses



4 Segments

Champions · Fidèles · Potentiels ·
Dormants



Flask Live

Application web déployée

Recommandations Métier

1

Campagnes de réactivation pour les Dormants dès 60 jours d'inactivité (offres ciblées, rappels email)

3

Surveiller la satisfaction comme signal précoce de churn — une chute soudaine est un indicateur fort

2

Programme de fidélité pour faire progresser les Potentiels vers le segment Fidèles

4

Intégrer le modèle Random Forest dans le CRM pour un scoring churn automatique en temps réel

"La qualité du modèle dépend avant tout de la qualité de la préparation des données."